

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Факультет электронно-информационных систем
Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1
Специальность АС-68

Выполнил:

Студент 3-го курса

Группы АС-68

Дворак В. А

Проверил:

А. А. Крощенко

Ст. преп. кафедры ИИТ,

«__» _____ 2026 г.

Брест 2026

Цель работы: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Общее задание:

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.
2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).
3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).
4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.
5. Выполнить нормализацию или стандартизацию числовых признаков.
6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.
7. Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

Вариант 4

Выборка Wine Quality. Содержит физико-химические показатели красного и белого вина и оценку его качества по шкале.

Задачи:

1. Загрузите данные и выведите информацию о типах столбцов.

Код программы:

```
import pandas as pd
# Загружаем датасет. Разделитель – точка с запятой
df = pd.read_csv(r'C:\питон\project\ml_as68\reports\Dvorak\1\src\winequality-white.csv', sep=';')
pd.set_option('display.max_rows', None)           # Показывать все строки
pd.set_option('display.max_columns', None)         # Показывать все столбцы
pd.set_option('display.width', None)               # Без ограничения по ширине
pd.set_option('display.max_colwidth', None)        # Полная ширина столбцов
print(df)
print("\nИнформация о типах столбцов:")
print(df.dtypes)
```

```
Информация о типах столбцов:
fixed acidity      float64
volatile acidity   float64
citric acid        float64
residual sugar     float64
chlorides          float64
free sulfur dioxide float64
total sulfur dioxide float64
density            float64
pH                 float64
sulphates          float64
alcohol            float64
quality            int64
dtype: object
```

2. Преобразуйте целевую переменную quality в категориальную: "плохое" (<=4), "среднее" (5-6), "хорошее" (>=7).

```
import pandas as pd
df = pd.read_csv(r'C:\питон\project\ml_as68\reports\Dvorak\1\src\winequality-white.csv', sep=';')
pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)
pd.set_option('display.width', None)
pd.set_option('display.max_colwidth', None)
# Функция категоризации качества вина
def quality_to_category(q):
    if q <= 4:
        return 'плохое'
    elif q <= 6:
        return 'среднее'
    else:
        return 'хорошее'
# Создаём новый категориальный столбец на основе quality
df['quality_cat'] = df['quality'].apply(quality_to_category)
print("\nЭто как выглядит с преобразованной Quality:")
print(df[['quality', 'quality_cat']].head(10))
print("\nКоличество образцов каждой категории качества:")
print(df['quality_cat'].value_counts())
```

Это как выглядит с преобразованной Quality:

quality	quality_cat
0	6 среднее
1	6 среднее
2	6 среднее
3	6 среднее
4	6 среднее
5	6 среднее
6	6 среднее
7	6 среднее
8	6 среднее
9	6 среднее

Количество образцов каждой категории качества:

quality_cat	
среднее	3655
хорошее	1060
плохое	183

3. Постройте столбчатую диаграмму, показывающую количество вин каждой новой категории качества.


```
import pandas as pd
import matplotlib.pyplot as plt
df = pd.read_csv(r'C:\питон\project\ml_as68\reports\Dvorak\1\src\winequality-white.csv', sep=';')
pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)
pd.set_option('display.width', None)
pd.set_option('display.max_colwidth', None)
# Функция категоризации качества вина
def quality_to_category(q):
    if q <= 4:
        return 'плохое'
    elif q <= 6:
        return 'среднее'
    else:
        return 'хорошее'
# Создаём новый категориальный столбец
df['quality_cat'] = df['quality'].apply(quality_to_category)
```

```
# Считаем количество вин в каждой категории (фиксируем порядок)
order = ['плохое', 'среднее', 'хорошее']
counts = df['quality_cat'].value_counts().reindex(order)
# Цвета для категорий
colors = ['red', 'orange', 'green']
fig, ax = plt.subplots(figsize=(8, 6))
bars = ax.bar(counts.index, counts.values, color=colors, alpha=0.7)
# Подписываем значения над каждым столбцом
for bar in bars:
    height = bar.get_height()
    ax.text(bar.get_x() + bar.get_width() / 2,
            height + 20,
            str(int(height)),
            ha='center',
            fontsize=11)
ax.set_xlabel('Категория качества')
ax.set_ylabel('Количество вин')
ax.set_title('Количество вин каждой категории качества', fontsize=14)
plt.tight_layout()
plt.show()
```




4. Проверьте корреляцию между fixed acidity и pH. Визуализируйте эту зависимость на диаграмме рассеяния.

```
import pandas as pd
import matplotlib.pyplot as plt
df = pd.read_csv(r'C:\питон\project\ml_as68\reports\Dvorak\1\src\winequality-white.csv', sep=';')
pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)
pd.set_option('display.width', None)
pd.set_option('display.max_colwidth', None)
# Считаем коэффициент корреляции Пирсона между fixed acidity и pH
correlation = df['fixed acidity'].corr(df['pH'])
print("\nКорреляция между fixed acidity и pH:")
print(correlation)
# Диаграмма рассеяния
fig, ax = plt.subplots(figsize=(8, 6))
ax.scatter(df['fixed acidity'], df['pH'], color='blue', alpha=0.5)
ax.set_xlabel('Fixed acidity')
ax.set_ylabel('pH')
ax.set_title('Зависимость pH от fixed acidity', fontsize=14)
plt.tight_layout()
plt.show()
```



5. Найдите признак с наибольшим количеством выбросов, используя "ящик с усами" (box plot).

```
import pandas as pd
import matplotlib.pyplot as plt
# Загрузка данных
df = pd.read_csv(r'C:\питон\project\ml_as68\reports\Dvorak\1\src\winequality-white.csv', sep=';')
# Настройки отображения
pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)
pd.set_option('display.width', None)
pd.set_option('display.max_colwidth', None)
# Общий "ящик с усами" по всем числовым признакам
df.boxplot(grid=False, rot=45, figsize=(14, 6))
plt.title('Распределение числовых признаков (box plot)')
plt.suptitle("") # Убираем автоматический заголовок
plt.xlabel('Признаки')
plt.ylabel('Значение')
plt.show()
# Программный подсчёт выбросов по правилу IQR
# Выброс = значение < Q1 - 1.5*IQR или > Q3 + 1.5*IQR
def count_outliers(series):
    q1 = series.quantile(0.25)
    q3 = series.quantile(0.75)
    iqr = q3 - q1
    lower = q1 - 1.5 * iqr
    upper = q3 + 1.5 * iqr
    return ((series < lower) | (series > upper)).sum()
numeric_cols = df.drop('quality', axis=1).columns
outliers =
df[numeric_cols].apply(count_outliers).sort_values(ascending=False)
print("\nКоличество выбросов по каждому признаку:")
print(outliers)
print("\nПризнак с наибольшим количеством выбросов:")
print(outliers.idxmax(), "-", outliers.max(), "выбросов")
# Отдельный "ящик с усами" для признака-лидера
top_feature = outliers.idxmax()
df.boxplot(column=top_feature, grid=False, figsize=(6, 6))
plt.title(f'Распределение {top_feature}')
plt.suptitle("") # Убираем автоматический заголовок
plt.xlabel(top_feature)
plt.ylabel('Значение')
plt.show()
```



6. Выполните стандартизацию всех числовых признаков.

import pandas as pd

from sklearn.preprocessing import StandardScaler

df = pd.read_csv(r'C:\питон\project\ml_as68\reports\Dvorak\1\src\winequality-white.csv', sep=';')

pd.set_option('display.max_rows', None)

pd.set_option('display.max_columns', None)

pd.set_option('display.width', None)

pd.set_option('display.max_colwidth', None)

numeric_columns = df.select_dtypes(include='number').columns

scaler = StandardScaler()

df[numeric_columns] = scaler.fit_transform(df[numeric_columns])

print("\nСтандартизированные данные:")

print(df)

print("\nСтатистика стандартизированных признаков:")

print(df[numeric_columns].describe())

Стандартизированные данные:												
	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
0	0.172097	-0.081770	0.213280	2.821349	-0.035355	0.569932	0.744565	2.331512	-1.246921	-0.349184	-1.393152	0.137870
1	-0.657501	0.215896	0.048001	-0.944765	0.147747	-1.253019	-0.149685	-0.009154	0.740029	0.001342	-0.824276	0.137870
2	1.475751	0.017452	0.543838	0.100282	0.193523	-0.312141	-0.973336	0.358665	0.475102	-0.436816	-0.336667	0.137870
3	0.409125	-0.478657	-0.117278	0.415768	0.559727	0.687541	1.121091	0.525855	0.011480	-0.787342	-0.499203	0.137870
4	0.409125	-0.478657	-0.117278	0.415768	0.559727	0.687541	1.121091	0.525855	0.011480	-0.787342	-0.499203	0.137870
5	1.475751	0.017452	0.543838	0.100282	0.193523	-0.312141	-0.973336	0.358665	0.475102	-0.436816	-0.336667	0.137870
6	-0.776015	0.414339	-1.439511	0.120000	-0.035355	-0.312141	-0.055553	0.291789	-0.054751	-0.173921	-0.743008	0.137870
7	0.172097	-0.081770	0.213280	2.821349	-0.035355	0.569932	0.744565	2.331512	-1.246921	-0.349184	-1.393152	0.137870
8	-0.657501	0.215896	0.048001	-0.944765	0.147747	-1.253019	-0.149685	-0.009154	0.740029	0.001342	-0.824276	0.137870
9	1.475751	-0.577879	0.791757	-0.964483	-0.081131	-0.429751	-0.220283	-0.076030	0.210175	-0.349184	0.394746	0.137870
10	1.475751	-0.081770	0.626478	-0.974342	-0.584661	-1.429433	-1.773454	-1.079173	-1.313153	0.614763	1.207427	-0.991374

Статистика стандартизированных признаков:

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
count	4.898000e+03	4.898000e+03	4.898000e+03	4.898000e+03	4.898000e+03	4.898000e+03	4.898000e+03	4.898000e+03	4.898000e+03	4.898000e+03	4.898000e+03	4.898000e+03
mean	-3.481630e-16	4.497106e-16	1.160543e-17	-1.066249e-16	3.133467e-16	-1.015476e-17	-4.642174e-17	3.247201e-14	-1.183754e-15	-8.218098e-16	-3.713713e-16	-3.713713e-16
std	1.000102e+00	1.000102e+00	1.000102e+00	1.000102e+00	1.000102e+00	1.000102e+00	1.000102e+00	1.000102e+00	1.000102e+00	1.000102e+00	1.000102e+00	1.000102e+00
min	-3.620351e+00	-1.966985e+00	-2.761743e+00	-1.141944e+00	-1.683274e+00	-1.958677e+00	-3.044230e+00	-2.313038e+00	-3.101408e+00	-2.364709e+00	-2.043214e+00	-2.043214e+00
25%	-6.570511e-01	-6.771010e-01	-5.304757e-01	-9.250474e-01	-4.473347e-01	-7.237750e-01	-7.144739e-01	-7.707066e-01	-6.508363e-01	-6.997104e-01	-8.242714e-01	-8.242714e-01
50%	-6.493106e-02	-1.809917e-01	-1.172780e-01	-2.349217e-01	-1.269060e-01	-7.692173e-02	-1.026189e-01	-9.609320e-02	-5.475133e-02	-1.739212e-01	-9.286214e-02	-9.286214e-02
75%	5.276390e-01	4.143393e-01	4.611988e-01	6.918185e-01	1.935226e-01	6.287364e-01	6.739664e-01	6.930457e-01	6.075653e-01	5.271310e-01	7.198114e-01	7.198114e-01
max	8.705106e+00	8.153643e+00	1.095642e+01	1.171411e+01	1.374308e+01	1.491831e+01	7.098444e+00	1.503130e+01	4.184075e+00	5.171602e+00	2.995314e+00	2.995314e+00

Вывод: Получил практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научился выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

