

Министерство образования Республики Беларусь  
Учреждение образования  
«Брестский Государственный технический университет»  
Кафедра ИИТ

Лабораторная работа №1  
По дисциплине «ОМО»

Выполнил:  
Студент 3-го курса  
Группы АС-68  
Жуков А.А.  
Проверил:  
Крощенко А.А.

**Цель работы:** Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

## Ход работы

### Общее задание:

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.
2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).
3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).
4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.
5. Выполнить нормализацию или стандартизацию числовых признаков.
6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.
7. Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

## Вариант 2

Выборка Boston Housing. Содержит информацию о жилье в разных районах Бостона, включая уровень преступности, количество комнат и медианную стоимость.

Задачи:

1. Загрузите данные и выведите их основные статистические характеристики (.describe()).
2. Постройте матрицу корреляции и визуализируйте ее с помощью тепловой карты (heatmap).
3. Найдите признак, наиболее сильно коррелирующий с целевой переменной MEDV (медианная стоимость дома).
4. Постройте диаграмму рассеяния (scatter plot) для этого признака и MEDV.
5. Нормализуйте все числовые признаки, приведя их к диапазону от 0 до 1.
6. Визуализируйте распределение уровня преступности (CRIM) с помощью гистограммы.

### Код программы :

```
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns

df = pd.read_csv("BostonHousing.csv")

print(df.describe())

print(df.dtypes)

print(df.isnull())

corr = df.corr()
corr_with_medv =
df.corr(numeric_only=True)['MEDV'].sort_values(ascending=False)
print(corr_with_medv)

plt.figure(figsize=(10, 8))
sns.heatmap(corr, annot=True, cmap='coolwarm', fmt='.2f')
plt.title("Матрица корреляции")
plt.show()

plt.figure(figsize=(8, 6))
plt.scatter(df['MEDV'], df['LSTAT'], s=20, c='steelblue', alpha=0.6,
edgecolors='black', linewidths=0.3)
plt.xlabel('MEDV')
plt.ylabel('LSTAT')
plt.show()

plt.figure(figsize=(8, 6))
plt.hist(df['CRIM'], bins= 30, color='steelblue', edgecolor='black')
plt.xlabel('Уровень преступности')
plt.ylabel('Частота')
plt.title('Распределение уровня преступности')
plt.show()

numerics_cols = df.select_dtypes(include='number').columns
df[numerics_cols] = (df[numerics_cols] - df[numerics_cols].min()) /
(df[numerics_cols].max() - df[numerics_cols].min())


print("После нормализаций")
print(df[numerics_cols].describe().loc[['min', 'max']])
```

В данном коде изложены все задания данной лабораторной работы ( в методах заданий). Разберем результаты вывода данной программы.

### Вывод результатов первого задания:

|       | CRIM       | ZN         | INDUS      | CHAS       | NOX        | RM         | AGE        | DIS        | RAD        | TAX        | PTRATIO    | LSTAT      | MEDV       | CAT. MEDV  |
|-------|------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|
| count | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 | 506.000000 |
| mean  | 3.613524   | 11.363636  | 11.136779  | 0.069170   | 0.554695   | 6.284634   | 68.574901  | 3.795043   | 9.549407   | 408.237154 | 18.455534  | 12.653063  | 22.532886  | 0.166008   |
| std   | 8.601545   | 23.322453  | 6.860353   | 0.253994   | 0.115878   | 0.702617   | 28.148861  | 2.105710   | 8.707259   | 168.537116 | 2.164946   | 7.141062   | 9.197104   | 0.372456   |
| min   | 0.006320   | 0.000000   | 0.460000   | 0.000000   | 0.385000   | 3.561000   | 2.900000   | 1.129600   | 1.000000   | 187.000000 | 12.600000  | 1.730000   | 5.000000   | 0.000000   |
| 25%   | 0.082045   | 0.000000   | 5.190000   | 0.000000   | 0.449000   | 5.885500   | 45.025000  | 2.100175   | 4.000000   | 279.000000 | 17.400000  | 6.950000   | 17.025000  | 0.000000   |
| 50%   | 0.256510   | 0.000000   | 9.690000   | 0.000000   | 0.538000   | 6.208500   | 77.500000  | 3.207450   | 5.000000   | 330.000000 | 19.050000  | 11.360000  | 21.200000  | 0.000000   |
| 75%   | 3.677083   | 12.500000  | 18.100000  | 0.000000   | 0.624000   | 6.623500   | 94.075000  | 5.188425   | 24.000000  | 666.000000 | 20.200000  | 16.955000  | 25.000000  | 0.000000   |
| max   | 88.976200  | 100.000000 | 27.740000  | 1.000000   | 0.871000   | 8.780000   | 100.000000 | 12.126500  | 24.000000  | 711.000000 | 22.000000  | 37.970000  | 50.000000  | 1.000000   |

## Вывод результатов второго задания:



## Вывод результатов третьего задания:

```


MEDV      1.000000
CAT. MEDV  0.789789
RM         0.695360
ZN         0.360445
DIS        0.249929
CHAS       0.175260
AGE        -0.376955
RAD        -0.381626
CRIM       -0.388305
NOX        -0.427321
TAX        -0.468536
INDUS      -0.483725
PTRATIO    -0.507787
LSTAT      -0.737663
Name: MEDV, dtype: float64

```

A scatter plot titled 'Figure 1' showing the relationship between 'MEDV' (Median Value) on the x-axis and 'LSTAT' (Lower Status of the Tractor) on the y-axis. The x-axis ranges from 0 to 50, and the y-axis ranges from 0 to 35. The plot displays a large number of blue data points, showing a clear negative correlation: as MEDV increases, LSTAT generally decreases. The data points are most densely clustered between MEDV values of 10 and 25, and LSTAT values of 5 and 20. There is a notable outlier at approximately (5, 37). The plot is displayed in a window titled 'Figure 1' with standard window controls (minimize, maximize, close) in the top right corner. A toolbar at the bottom of the image contains icons for home, navigation, zoom, and save.

[illegible]

Вывод результатов шестого задания:



Вывод: мы приобрели практические знания по работе с Pandas, Matplotlib, а также научились анализировать датасеты для дальнейшего обучения моделей на их основе.